基于 MT5 与清华 TSLib 的深度时间序列交易研究

数据源：MT5 模拟账户历史行情　模型库：Time-Series-Library (TSLib)

复现实验仓库：`https://github.com/GoodNight0721/Time-Series-Library`

---

1. 任务理解与研究闭环

题目要求把 MT5 历史行情与清华大学龙明盛课题组维护的 TSLib 结合起来，做出一套能够落到交易指标上的最小研究闭环，并回答两个核心问题：第一，模型预测是否真的能够转化成可审计的交易表现；第二，在哪些品种、哪些周期下，深度学习相对简单线性模型更有价值。

研究流程如下：

1. 从 MT5 导出真实 K 线，构造成 TSLib 可直接读取的 `custom CSV`；
2. 用统一切分规则训练多类 TSLib 模型，保存 `pred.npy` 与 `true.npy`；
3. 将预测收益映射成多空信号，并在统一成本假设下计算胜率、盈亏比、累计收益与最大回撤；
4. 对比不同资产、不同周期、不同模型，判断“深度学习更适合哪里”。

本文重点放在三件事上：工程链路是否闭环、回测口径是否正确、结论是否足够克制。

2. 数据与实验设计

2.1 数据来源与资产覆盖

本次实验使用 MT5 模拟账户可直接获取的三类资产：

- 外汇：`EURUSD`、`GBPUSD`、`USDJPY`
- 贵金属：`XAUUSD`、`XAGUSD`
- 指数 CFD：`US500`、`USTEC`

周期覆盖上，外汇与黄金使用 `M15/H1/H4`，白银与指数使用 `H1/H4`。大部分组合统一导出约 `12000` 根 K 线；`USTEC H4` 由于 MT5 历史缓存限制，仅有约 `5493` 根。

导出的每条样本包含时间戳以及 12 个数值特征，其中预测目标为 `close`。其余特征主要包括：

- 价格与成交字段：`open`、`high`、`low`、`tick_volume`、`spread`、`real_volume`
- 派生波动字段：`range`、`body`、`return_1`、`log_return_1`、`hl_ratio`

2.2 训练与回测口径

所有实验统一使用 TSLib 的 `Dataset_Custom` 切分逻辑：

- 训练集：70%
- 验证集：10%
- 测试集：20%

基础超参数设定为：

- `seq_len = 96`
- `label_len = 48`
- `pred_len = 1`
- `batch_size = 64`
- `d_model = 64`
- `d_ff = 128`
- `n_heads = 4`

模型分为三组：

- 线性基线：`DLinear`
- 主力深度模型：`PatchTST`
- 额外补充模型：`TimesNet`、`iTransformer`

另外补充测试了更多工具箱模型。`TimeMixer` 在当前自定义频率配置下暴露出频率映射与前向维度问题，`SegRNN` 在本任务设定下出现形状错误，因此未纳入主比较表。这表明并不是所有 TSLib 模型都能在 MT5 自定义数据接口上直接稳定落地。

交易映射规则统一定义为：

- 当预测下一根收益率大于阈值 θ 时做多；
- 当预测下一根收益率小于 $-\theta$ 时做空；
- 否则空仓。

基础回测口径采用：

- 阈值：`3 bps`
- 往返总成本：`2 bps`
- 持有期：`1` 根 K 线

3. 实现审计与口径校验

结果解释前，对以下几处链路做了审计：

1. 检查了 `Dataset_Custom` 的测试集切分、滑窗索引和 `pred.npy/true.npy` 的保存逻辑，确认预测值与原始 CSV 在时间上严格对齐。
2. 手工抽查了 `GBPUSD M15` 的测试样本，验证 `true.npy` 中标签与对应时间点的原始 `close` 一致，不存在标签错位。

3. 修正了早期版本中的成本口径问题：`cost_bps` 应解释为往返总成本，而不是重复乘以 2 之后再扣减。
4. 额外比较了“上一根收盘到下一根收盘”和“下一根开盘到下一根收盘”两种实现，数值会变化，但不会推翻方向性结论。

下文的负收益并非由代码错位造成，而是在当前任务定义和成本假设下得到的结果。

4. 核心结果

4.1 基础设定下的主结果

表 1 展示了外汇主流货币对上，`DLinear` 与 `PatchTST` 的核心比较。这里保留的是最能回答题目的部分：同一品种、同一周期下，深度模型相对线性基线到底提升了多少。

表 1: 外汇主组合上 DLinear 与 PatchTST 的对比（3bps 阈值，2bps 往返成本）

品种	周期	DLinear 累计收益	PatchTST 累计收益	收益改善	PatchTST 最大回撤
EURUSD	M15	-31.40%	-12.34%	+19.06%	12.36%
GBPUSD	M15	-30.95%	-13.37%	+17.58%	13.37%
USDJPY	M15	-30.85%	-17.97%	+12.88%	18.00%
EURUSD	H1	-35.12%	-21.85%	+13.27%	22.21%
GBPUSD	H1	-31.48%	-22.88%	+8.61%	23.23%
USDJPY	H1	-38.69%	-28.98%	+9.71%	28.98%
EURUSD	H4	-35.68%	-29.83%	+5.85%	31.19%
GBPUSD	H4	-30.32%	-31.14%	-0.82%	32.33%
USDJPY	H4	-33.51%	-29.30%	+4.21%	31.52%

表中可见，深度模型的相对增益主要集中在外汇主流货币对的 `M15/H1` 上；同时，基础设定下绝大多数组合仍然为负，说明当前信号强度还不足以稳定覆盖交易摩擦。

4.2 跨资产与多模型补充

若只看外汇，会得到“深度学习总体优于线性模型”的结论；这一结论在跨资产上并不成立。将实验扩展到贵金属、指数和更多模型后，结果如表 2 所示。

表 2: 跨资产与额外模型的代表性结果

品种	周期	模型	累计收益	最大回撤	盈利因子
EURUSD	H1	TimesNet	-20.12%	20.56%	0.518
EURUSD	H4	iTransformer	-22.95%	25.36%	0.829
USTEC	H4	DLinear	+7.49%	17.92%	1.050
USTEC	H4	iTransformer	+7.54%	10.47%	1.051
USTEC	H4	PatchTST	-8.39%	22.15%	0.954
US500	H1	PatchTST	-23.05%	24.26%	0.812
XAGUSD	H4	DLinear	-80.72%	84.96%	0.837
XAGUSD	H4	PatchTST	-37.91%	61.49%	0.962

这里最关键的发现有三个：

1. 深度学习并不是在所有资产上都最优。当前设定下，USTEC H4 的最好结果来自 iTransformer 与 DLinear，而不是 PatchTST。
2. TimesNet 在 H1 外汇上是可用的，而且表现接近 PatchTST；但它对 15min 和 4h 自定义频率的兼容性较差。
3. 贵金属在当前单步交易设定下整体偏弱，尤其白银的波动虽然大，但可交易的净收益结构并不理想。

据此，可将结论概括为：深度学习的相对优势集中在部分市场与周期上，跨资产后结果明显分化。

4.3 已完成的补充实验

围绕训练轮数、阈值过滤和模型集合，额外完成了三类补充实验。

第一类：延长训练轮数。将外汇核心组合上的 PatchTST 从 3 epochs 提高到 10 epochs。结果普遍改善，但改善幅度有限：

- EURUSD M15：-12.34% 改善到 -10.76%
- GBPUSD M15：-13.37% 改善到 -12.01%
- USDJPY H4：-29.30% 改善到 -27.65%

这说明 3 epochs 偏少，但并不是唯一瓶颈。更长训练可以改善结果，却不足以从根本上把大多数组合翻成正收益。

第二类：阈值过滤。在 10 epochs 的 PatchTST 结果上重新做了阈值敏感性分析。代表性结果见表 3。

表 3: PatchTST（10 epochs）阈值敏感性代表结果

品种	周期	阈值	交易次数	累计收益	最大回撤
GBPUSD	M15	3 bps	728	-12.01%	12.01%
GBPUSD	M15	12 bps	28	+0.47%	0.18%
GBPUSD	M15	15 bps	8	+0.15%	0.11%
USDJPY	H4	20 bps	426	+0.60%	6.67%

阈值结果表明，模型的 alpha 主要集中在高置信度样本上；在基础设定下，大量边际信号进入交易后，净收益被交易成本明显侵蚀。

第三类:扩展模型集合。补跑了 iTransformer，并尝试了 TimeMixer 与 SegRNN。iTransformer 在 USTEC H4 上与 DLinear 几乎持平且略优；TimeMixer 与 SegRNN 暂时没有在这套 MT5 自定义频率接口上稳定跑通。模型可用性也纳入比较范围。

5. 哪个品种、哪个周期更适合深度学习

这里需要区分“适合深度学习”与“当前绝对收益最好”两个问题。

5.1 如果按“深度模型相对线性模型的增益”来定义

排序为：

$$\texttt{EURUSD} \quad > \quad \texttt{GBPUSD} \quad > \quad \texttt{USDJPY}$$

周期排序是：

$$\texttt{M15} \quad > \quad \texttt{H1} \quad > \quad \texttt{H4}$$

原因是：

- EURUSD 与 GBPUSD 在 M15/H1 上，对 DLinear 的改善最明显；
- USDJPY 也有改善，但整体略弱于前两者；
- 到 H4 时，深度模型相对线性模型的边际优势明显收缩。

若以“深度模型相对简单基线的增益”来回答,则结论是:**外汇主流货币对,尤其是 EURUSD/GBPUSD 的 M15 与 H1**。

5.2 如果按“当前测试设定下绝对收益最好”来定义

若按绝对收益衡量,则 **USTEC H4** 是当前已跑组合中的正收益样本,最好结果来自 iTransformer（+7.54%）和 DLinear（+7.49%），并不是 PatchTST。

> 在“深度学习是否比线性基线更有增益”这个问题上，外汇 M15/H1 最适合深度学习；在“当前哪组参数下绝对收益最好”这个问题上，指数低频场景 USTEC H4 更突出，但其最优模型未必是传统意义上的深度 patch 模型。

6. 最终结论

最终结论如下：

> MT5 与 TSLib 可以被拼成一套可复现、可审计的最小研究闭环，并能落到胜率、盈亏比和最大回撤这些交易指标上。基础设定下，大多数组合仍为负收益，但这并不意味着模型没有信息，而是意味着当前策略还停留在“弱正毛利 alpha、尚未稳定覆盖交易摩擦”的阶段。若把“适合深度学习”定义为相对线性模型的增益，则最适合的标的是 EURUSD 与 GBPUSD，最适合的周期是 M15，其次是 H1。若看当前绝对收益，则 USTEC H4 是最有价值的继续研究样本，而且最佳结果来自 iTransformer/DLinear，说明跨资产后不应预设深度模型一定占优。

说明：正文中引用的实验结果已对应落地在仓库 quant/outputs 与 results 目录中，可直接复核。